«ربات هوشمند جستجوی ملک»

پریناز عاکف

پروژه پایانی بوت کمپ هم مسیر نشان

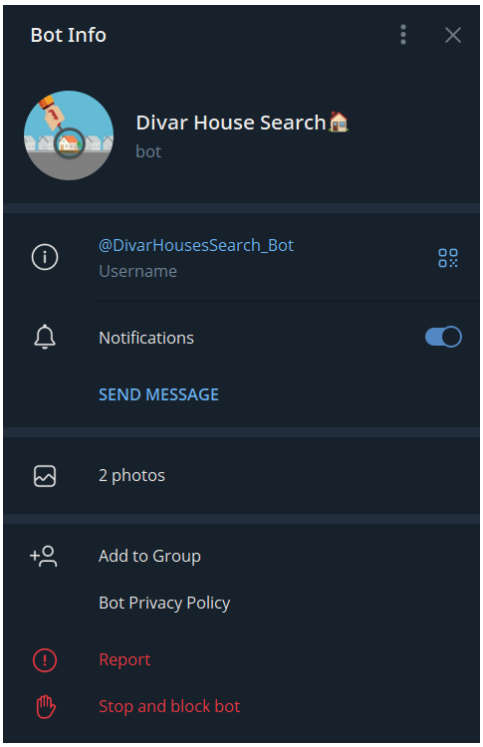
تابستان ۱۴۰۴

مقدمه

این پروژه به عنوان پروژه نهایی بوت‌کمپ طراحی انجام شد و هدف آن ساخت یک دستیار هوشمند گفتگو محور برای جستجوی خانه در دیتاست دیوار و نمایش نتایج دلخواه کاربر بود.

در این پروژه سیستمی طراحی شد که بتواند:

- درخواست‌های متنی کاربر به زبان فارسی را درک کند،
- ویژگی‌های کلیدی (ستون ها) مورد نیاز کاربر را استخراج کند
- داده‌ها را verify و نرمال‌سازی نماید
- نتایج مرتبط را از دیتاست بزرگ املاک دیوار استخراج کند
- و در نهایت پاسخ‌هایی دوستانه و راهنما در اختیار کاربر بگذارد با نتایج منطبق با درخواست کاربر



شکل ۱ - نمایی از ربات

این سیستم در قالب یک ربات تلگرامی پیاده سازی شد تا کاربر بتواند در یک محیط واقعی و کاربردی با آن تعامل کند.

شناخت و اعمال روی دیتاست

دیتاست استفاده شده شامل بیش از یک میلیون آگهی املاک از پلتفرم دیوار بود. هر آگهی دارای ویژگی‌هایی مانند:

- نوع ملک (آپارتمان، ویلا، دفتر اداری و ...)
- نوع معامله (خرید، فروش، رهن، اجاره)
- شهر و محله
- قیمت، متراژ، تعداد اتاق، طبقه، آسانسور، پارکینگ و ...

با توجه به حجم و تنوع داده ها، پیش‌پردازش (Preprocessing) بخش بسیار مهمی از پروژه بود.

پیش‌پردازش و تحلیل داده‌ها

مشکلات اولیه داده‌ها: در مرحله تحلیل اولیه، مشکلات زیادی شناسایی شد:

- وجود اعداد فارسی در کنار اعداد انگلیسی.
- سال ساخت با فرمت‌های متفاوت (سال شمسی، عبارت «قبل از ۱۳۷۰» و ...).
- ستون‌های بولی با مقادیر ناهمگون.(True, False, true, false, unselect)
- داده‌های پرت مانند مقدار «۳۰+» برای تعداد طبقات.
- ستون‌هایی با مقادیر بی‌فایده مثلا property_type که فقط nan داشت.

مراحل پاکسازی

بر اساس نوت های جمع‌آوری شده، مراحل زیر انجام شد:

- تبدیل نوع داده‌ها: تمام ستون‌ها به نوع صحیح (int، float، boolean یا String) تبدیل شدند.
- تبدیل اعداد فارسی به انگلیسی.
- مدیریت مقادیر :unselect تبدیل به NaN یا حذف کامل ستون در صورت بی‌فایده بودن.
- ویژگی‌های جدید: استخراج year_created و month_created از created_at_month
- نرمال‌سازی مقادیر بولی: ادغام True/False در ستون‌هایی مثل.has_balcony
- تعدیل مقادیر عددی خاص: «۳۰+» به ۴۰، «more_than_8»به ۹، و «قبل از ۱۳۷۰» به ۱۳۶۹
- تبدیل کلمات فارسی به عدد: یک، دو، پنج یا بیشتر ← ۱، ۲، ۶.

verification و range ها: مقادیر ورودی کاربر با حداقل/حداکثر مقادیر دیتاست مقایسه شدند.

مقادیر خارج از محدوده با «out of range ❌» مشخص شدند. برای نام شهر و محله از fuzzy matching استفاده شد (مثلا برای mashhad و mashad).

نمونه برای range:

```
Testing for: {'city_slug': 'mashad', 'neighborhood_slug': 'hashemieh',
'min_rooms_count': 2, 'max_price_value': 999999999999999, 'has_balcony':
True}

--------------------Verification--------------------

{'city_slug': 'mashhad',

 'neighborhood_slug': 'hashemieh',

 'min_rooms_count': 2,

 'max_price_value': '❌out of range',

 'has_balcony': True}
```

معماری دستیار هوشمند

معماری سیستم به این صورت طراحی شد:

۱. ورودی کاربر: کاربر پیام خود را به فارسی در تلگرام ارسال می‌کند.

۲. استخراج فیلدها: متن با استفاده از OpenAI API پردازش و به JSON ساختاریافته تبدیل می‌شود. مثال:

ورودی:

s1 = "من دنبال یک خونه توی هاشمیه مشهد هستم. حداقل دو خواب داشته باشه و پول پیشش بیشتر از ۸۰۰ میلیون نباشه."

خروجی:

```
{'city_slug': 'mashhad', 'neighborhood_slug': 'hashemieh', 'min_rooms_count':
2, 'max_price_value': 800000000}
```

۳. اعتبارسنجی و نرمال‌سازی: مقادیر عددی، بولی و متنی بررسی و تصحیح شدند.

۴. فیلتر کردن دیتاست: فیلدهای معتبر روی dataframe اعمال می‌شوند.

۵. با استفاده از openai api پاسخ دوستانه (پاسخ کوتاه و غیررسمی فارسی) برای کاربر ساخته می‌شود.

۶. مدیریت حالت :(State Management) امکان مکالمه چند مرحله‌ای و اصلاح تدریجی درخواست فراهم شد.

توابع کلیدی

- parse_user_query(user_text) → استخراج فیلدها از متن کاربر
- validate_user_input(user_json, df) → بررسی صحت و محدوده مقادیر
- filter_dataframe(df, user_filters) → فیلتر کردن دیتاست بر اساس ورودی معتبر
- generate_friendly_response(...) → تولید پاسخ دوستانه به فارسی
- process_user_input(...) → حفظ state کاربر در طول مکالمه

امکانات تکمیلی:

پشتیبانی از پیشوند و پسوند های _max / _min برای بازه‌ها (مثلاً قیمت تا ۸۰۰ میلیون با **max**_price مشخص میشود). همچنین برای شباهت سنجی رشته ها در فیلد های شهر (city_slug) و محله (neighborhood_slug) از fuzzy matching استفاده شد. ورودی های invalid یا مبهم نیز مدیریت میشوند و ربات به آنها توجهی نمیکند، فقط با اطلاعاتی که دارد با جستجو پیش میرود.

پیاده سازی با ربات تلگرام

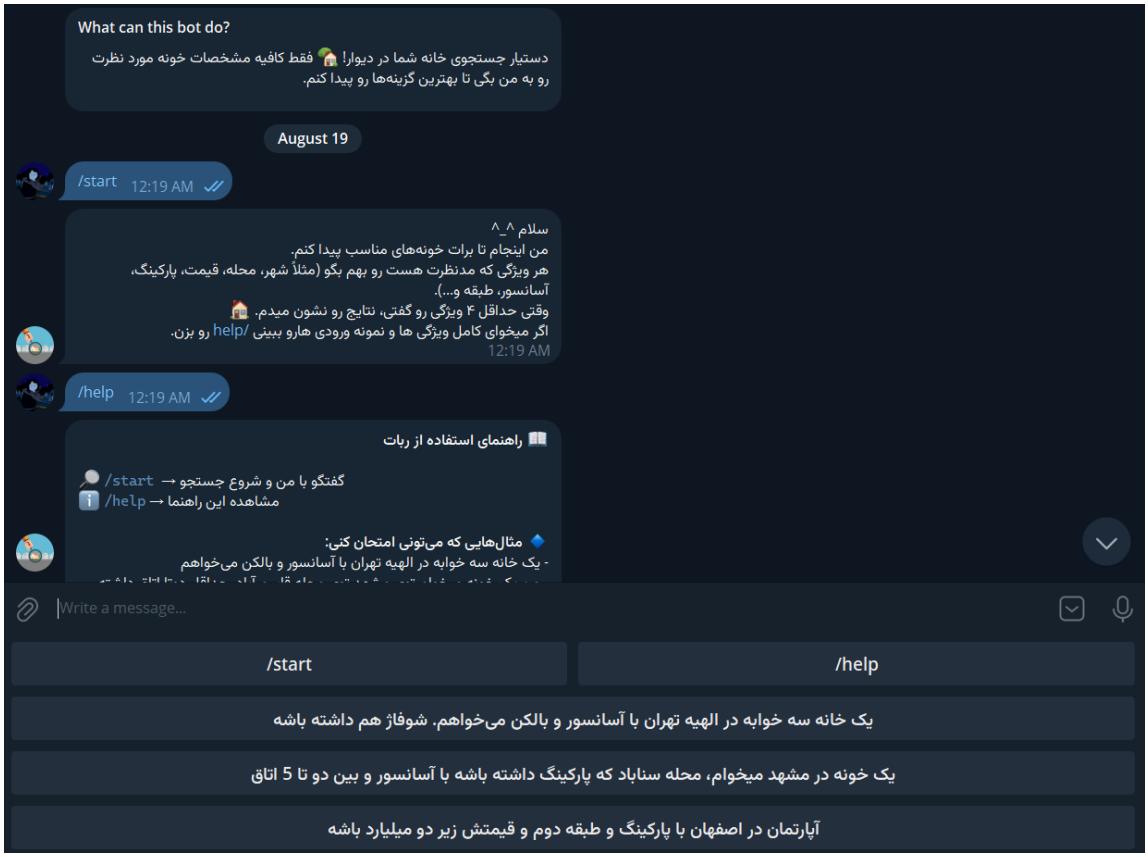
با لینک https://t.me/DivarHousesSearch_Bot میتوانید در صورت فعال بودن سرور با ربات تعامل داشته باشید.

برای استفاده عملی، کل سیستم به شکل یک Telegram bot پیاده‌سازی شد:

- ✓ ارتباط مستقیم با logic موجود در project_functions.py
- ✓ فیلتر و نمایش نتایج به صورت real-time
- ✓ پشتیبانی از مکالمه چندمرحله‌ای و به خاطر سپردن اطلاعات قبلی کاربر.

دستیار روی چندین سناریوی واقعی تست شد و توانست جملات پیچیده فارسی با چندین شرط را درک کند، ورودی‌های نامعتبر (مثل کالیفرنیا) را شناسایی کرد و قابل پیشتیبانی از مکالمه چند مرحله ای و اصلاح تدریجی درخواست بود.

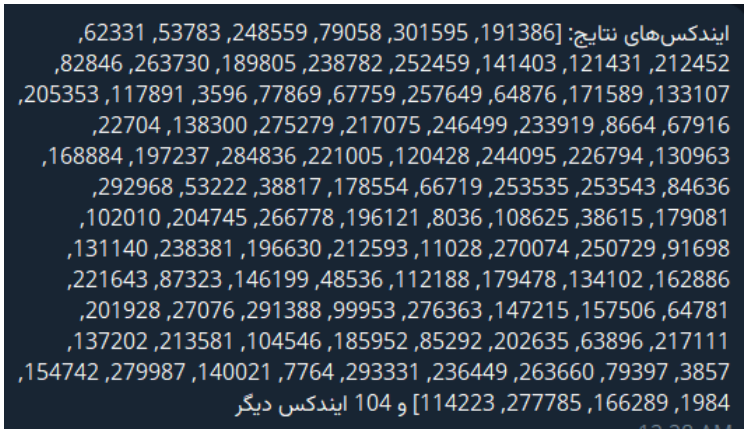
همچنین نتایج مرتبط با دقت بالا (precision) ارائه داد. با داشتن حداقل ۴ فیلد از کاربر، ربات شروع به جستجو در دیتاست میکند و تا زمانی که این فیلد ها را ندارد از کاربر درخواست اطلاعات بیشتر میکند و تعامل دارد.



شکل ۲ – رابط کاربری فارسی برای تعامل

نتیجه ها را با precision خوب نمایش داد و پس از نمایش نمونه هایی، سه گزینه در اختیار کاربر میگذارد که با هر کدام کاربر میتواند یکی از سه عمل زیر را انجام دهد:

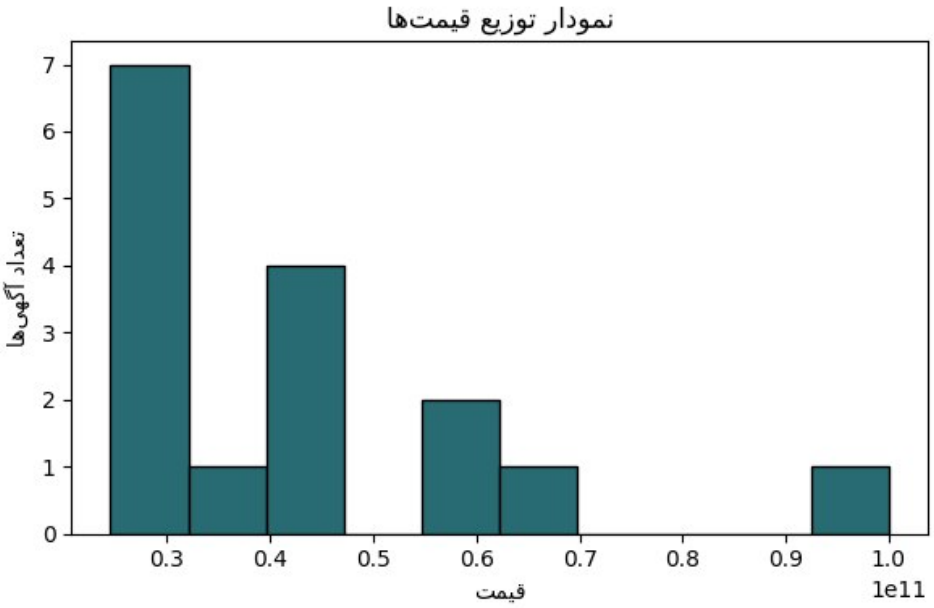
۱. دیدن کل ایندکس ها: با انتخاب این گزینه، کل ایندکس هایی که برای این جستجو پیدا شده بود برای کاربر چاپ میشود. اگر تعداد آن بیش از ۱۰۰ باشد، باقی آنها را به صورت تعداد نمایش میدهد. مثال:



شکل ۳ – نحوه نمایش بیش از صد ایندکس

۲. نمایش ۵ نتیجه بعدی: ربات پس از نمایش ۵ نتیجه، با فشرده شدن این دکمه، ۵ نتیجه بعدی را برای مشاهده میفرستد.
۳. نمایش histogram برای قیمت ها

برای درک بیشتر کاربر از قیمت در نتیجه برگردانده شده توسط ربات، نموداری به او برای بررسی نمایش داده میشود.



شکل ۳ – نمودار هیستوگرام برای قیمت نتایج جستجو

نتیجه گیری

از ویژگی های خوب این پیاده سازی، درک دقیق فیلدهای جستجوهای فارسی. مقاوم بودن در برابر تایپو ها یا اطلاعات ناقص و بی ربط و ارائه نتایج دقیق و مرتبط بود به همراه تلاش برای ساده و دوستانه کردن تجربه کاربر.